

So sánh Kiến trúc Deep Learning

CNN vs. ViT · RNN vs. Transformer · Zero-shot vs. Few-shot

Môn học: CO5085 – Deep Learning & Computer Vision Applications

Sinh viên: Nguyễn Trung Phong – MSSV: 2570047

Giảng viên: Lê Thành Sách

Đại học Bách Khoa TP.HCM – Học kỳ 2, 2025–2026

Nội dung trình bày

1. Giới thiệu & Câu hỏi nghiên cứu
2. Dữ liệu & Cài đặt thực nghiệm
3. Task 1 – Phân loại ảnh: CNN vs. ViT
4. Task 2 – Phân loại văn bản: RNN vs. Transformer
5. Task 3 – Học đa phương thức: Zero-shot vs. Few-shot
6. Phân tích mở rộng (Extensions)
7. Thảo luận & Kết luận

1. Giới thiệu

Ba câu hỏi nghiên cứu

Q1. CNN (ResNet-50) hay Vision Transformer (ViT-B/16) tốt hơn trong phân loại ảnh fine-grained?

Q2. RNN (GRU) hay DistilBERT tốt hơn trong phân loại văn bản?

Q3. CLIP có thể phân loại hiệu quả khi chỉ có rất ít mẫu có nhãn không?

Tại sao Transformer đang thay thế CNN/RNN?

- **Self-attention toàn cục** → nắm bắt quan hệ xa trong một bước
- **Pre-training quy mô lớn** → transfer learning hiệu quả hơn
- **Song song hóa** → huấn luyện nhanh hơn RNN sequential

2. Dữ liệu & Cài đặt

	CIFAR-100	20 Newsgroups	CIFAR-100 Superclasses
Nhiệm vụ	Phân loại ảnh	Phân loại văn bản	Multimodal
Classes	100 classes	20 classes	20 superclasses
Train	50,000 ảnh	~11,314 bài	— (zero/few-shot)
Test	10,000 ảnh	~7,532 bài	500 ảnh
Input	32×32 px (ViT: 224×224)	max 256 tokens	ảnh + text prompt

Cài đặt chung: AdamW · Gradient clipping (max_norm=1.0) · CosineAnnealingLR · Apple MPS (float32)

3. Task 1 – Phân loại ảnh: Kiến trúc

Model	Loại	Tham số	Pre-train	Head
ResNet-50	CNN – Residual blocks	25.6M	ImageNet-1K	Dropout(0.3) + FC(2048→100)
ViT-B/16	Transformer – Patch 16×16	86M	ImageNet-21K	FC(768→100)


- Đại diện: **CNN truyền thống** (ResNet-50) vs **Vision Transformer** (ViT-B/16)
- Cả hai fine-tune toàn bộ mạng trên CIFAR-100
- Hyperparameter: ResNet-50 `lr=1e-3` , ViT-B/16 `lr=5e-5` , 5 epochs

3. Task 1 – Kết quả

Model	Test Accuracy	F1-Macro
ResNet-50 (CNN)	44.11%	0.434
ViT-B/16 (Transformer)	89.60%	0.896

Nhận xét:

- ViT-B/16 vượt ResNet-50 gần **2× accuracy** (89.60% vs 44.11%)
- Cơ chế **self-attention toàn cục**: ViT học quan hệ giữa tất cả các patch ngay từ layer đầu
- CNN chỉ tổng hợp thông tin **cục bộ** qua từng lớp tích chập → thiết thời với ảnh nhỏ 32×32
- ViT pre-train trên **ImageNet-21K** (14M ảnh) vs ImageNet-1K (1.2M) → lợi thế về dữ liệu



4. Task 2 – Phân loại văn bản: Kiến trúc

Model	Loại	Tham số	Pre-train	Config
GRU	RNN bidirectional	~4M	Không	2 lớp, hidden=256, dropout=0.3
DistilBERT	Transformer 6L	66M	Wikipedia + BookCorpus	+ FC(768→20)


- Đại diện: **RNN truyền thống** (GRU) vs **Transformer** (DistilBERT)
- GRU: khởi tạo ngẫu nhiên, embedding từ tokenizer DistilBERT (vocab=30,522)
- DistilBERT: toàn bộ pretrained weights, `lr=2e-5`, 3 epochs, batch 32

4. Task 2 – Kết quả

Model	Test Accuracy	F1-Macro
GRU (RNN)	37.85%	0.361
DistilBERT (Transformer)	69.04%	0.668

Nhận xét:

- DistilBERT vượt GRU **+31.2 điểm** — khoảng cách lớn nhất trong 3 domain
- GRU xử lý **tuần tự** (sequential) → không song song hóa được, bottleneck với chuỗi dài
- DistilBERT: **self-attention** truy cập đồng thời mọi vị trí + pre-train ~16GB text



5. Task 3 – Multimodal CLIP: Phương pháp

CLIP ViT-B/32 (151M tham số) — Image & Text encoder đều frozen

Zero-shot:

$$\hat{y} = \arg \max_c \text{cosine}(\mathbf{v}, \mathbf{t}_c) \quad \text{với } \mathbf{t}_c = \text{encode}(\text{"a photo of a \{c\}"})$$

Không cần dữ liệu train — dùng hoàn toàn prior knowledge từ 400M cặp ảnh-văn bản.

Few-shot (K-shot):


- Trích xuất CLIP features (frozen) → train **linear classifier** $W \in \mathbb{R}^{512 \times 20}$
- $K \in \{1, 5, 10, 20\}$ ảnh/class
- Dataset: 20 superclass CIFAR-100, 500 ảnh test

5. Task 3 – Kết quả CLIP

Phương pháp	Shots	Test Accuracy	F1-Macro
Zero-shot	0	54.60%	0.517
Few-shot	1	32.80%	0.338
Few-shot	5	61.20%	0.622
Few-shot	10	76.40%	0.766
Few-shot	20	93.00%	0.932

Nhận xét:


- **1-shot < zero-shot**: 1 ảnh/class không đủ ước lượng phân phối → overfitting nghiêm trọng
- Từ **5-shot trở lên**: few-shot vượt zero-shot và tăng đều đặn
- **20-shot = 93%** chỉ với 400 ảnh train → CLIP features rất phong phú, phân ly tốt



6. Phân tích mở rộng

6.1 Grad-CAM – Khả năng diễn giải


Áp dụng Grad-CAM trên `layer4` của ResNet-50: heatmap bao phủ đúng vùng đối tượng chính, cho thấy mô hình tập trung vào đặc trưng ngữ nghĩa cấp cao.



6. Phân tích mở rộng

6.2 Error Analysis – Phân tích lỗi ResNet-50

Phần lớn lỗi xảy ra **trong cùng superclass** (gặm nhấm nhấm gặm nhấm, phương tiện nhấm phương tiện) — phù hợp với đặc trưng CIFAR-100 ở độ phân giải 32×32 .



6. Phân tích mở rộng

6.3 Chiến lược Fine-tuning

Chiến lược	Đặc điểm	Khi nào dùng
Freeze Backbone	Chỉ train head · Hội tụ nhanh	Dataset nhỏ · Tài nguyên hạn chế
Full Fine-tune	Train toàn mạng · Accuracy cao hơn	Dataset đủ lớn ($\geq 50K$ ảnh)

6.4 Demo App (Gradio)

Ứng dụng tương tác cho phép upload ảnh → nhận **top-5 predictions + confidence** từ ResNet-50 đã fine-tune.

Pipeline: `Resize(40)` → `CenterCrop(32)` → `Normalize` — đồng nhất với evaluation.

7. Thảo luận

Transformer vs. Kiến trúc truyền thống

	ResNet-50 / GRU	ViT-B/16 / DistilBERT
Kiến trúc	Local conv / Sequential RNN	Global self-attention
Tham số	25.6M / ~4M	86M / 66M
Pre-train data	ImageNet-1K / Không	ImageNet-21K / ~16GB text
Kết quả	44.1% / 37.9%	89.6% / 69%

So sánh có "công bằng" không?

- ViT pre-train **14M ảnh** vs ResNet-50 chỉ 1.2M → cách biệt dữ liệu 11×
- GRU khởi tạo **ngẫu nhiên** vs DistilBERT pre-train ~16GB text
→ Lợi thế Transformer một phần đến từ **quy mô pre-training**, không chỉ kiến trúc

7. Hạn chế & Hướng phát triển

Hạn chế:

- Số epochs ít (5 cho ResNet-50/GRU, 3 cho DistilBERT) do giới hạn tính toán trên MPS
- CIFAR-100 độ phân giải 32×32 không thuận lợi cho ViT (pre-train ở 224×224)
- Chưa báo cáo mean $\pm$ std trên nhiều lần chạy

Hướng phát triển:

- Tăng epochs + augmentation mạnh (MixUp, CutMix) để ResNet-50 cạnh tranh hơn
- Thử GRU với pretrained embeddings (GloVe/FastText) để so sánh công bằng hơn
- Fine-tune CLIP end-to-end thay vì chỉ linear probe

8. Kết luận

Domain	Winner	Accuracy
Image Classification	ViT-B/16	89.60%
Text Classification	DistilBERT	69.04%
Multimodal Few-shot	CLIP 20-shot	93.00%

Ba kết luận chính:

1. **Transformer vượt CNN và RNN** trên cả 3 domain nhờ self-attention toàn cục
2. **Pre-trained weights** là yếu tố then chốt — fine-tuning hiệu quả hơn train từ đầu nhiều lần
3. **CLIP few-shot** là hướng mạnh khi thiếu dữ liệu có nhãn — 93% accuracy chỉ với 400 ảnh train

Cảm ơn thầy đã lắng nghe!

Repository: <https://github.com/PhongNguyenTrung/hcmut-deeplearning-ass1>

Nguyễn Trung Phong – MSSV: 2570047

CO5085 – HCMUT – 2025–2026